Identifikasi Risiko Kambuhnya Asma di Tiga Titik Lokasi UPH Menggunakan Algoritma Random Forest dan Naive Bayes

1st Gebrina Augustine Padatu
Informatika
Universitas Pelita Harapan
Tangerang, Indonesia
01082230041@student.uph.edu

2nd Grace Patricia Ananta
Informatika
Universitas Pelita Harapan
Tangerang, Indonesia
01082230042@student.uph.edu

3rd Jennifer Christabelle
Informatika
Universitas Pelita Harapan
Tangerang, Indonesia
01082230009@student.uph.edu

Abstrak—Asma merupakan penyakit pernapasan kronis yang dapat kambuh secara tiba-tiba akibat paparan alergen atau kualitas udara yang buruk, dan jika tidak ditangani dengan baik dapat menyebabkan gangguan aktivitas harian hingga komplikasi serius. Untuk meminimalkan risiko tersebut, pemantauan kualitas udara secara real-time menjadi penting, terutama bagi individu yang memiliki riwayat asma. Penelitian ini bertujuan untuk mengidentifikasi tingkat risiko kambuhnya asma pada tiga titik lokasi di lingkungan Universitas Pelita Harapan, yaitu food junction, ruang kelas, dan perpustakaan, dengan memanfaatkan perangkat Internet of Things dan algoritma machine learning. Data lingkungan dikumpulkan secara real-time menggunakan sensor DHT11 dan MQ135 yang terintegrasi dengan mikrokontroler ESP8266 untuk mengukur suhu, kelembapan, dan konsentrasi gas. Setelah melalui tahap kalibrasi dan preprocessing, data dilabeli berdasarkan ambang batas risiko menjadi dua kategori, yaitu berisiko dan tidak berisiko. Dua algoritma machine learning, yaitu *Random Forest* dan *Naive Bayes* digunakan untuk membangun model klasifikasi. Hasil menunjukkan bahwa model Random Forest memiliki performa terbaik dengan akurasi sebesar 1.00 tanpa kesalahan klasifikasi, sedangkan model Naive Bayes memperoleh akurasi sebesar 0.9476 dan menunjukkan kesalahan pada sebagian kecil data tidak berisiko. Visualisasi distribusi risiko menunjukkan bahwa food junction merupakan lokasi dengan risiko tertinggi akibat tingginya konsentrasi gas yang dipengaruhi oleh aktivitas memasak, sedangkan perpustakaan memiliki kualitas udara terbaik. Penelitian ini membuktikan bahwa kombinasi IoT dan machine learning dapat digunakan secara efektif untuk memantau kualitas udara dan mengidentifikasi area yang berpotensi memicu kambuhnya asma, sehingga dapat membantu penderita asma dalam menghindari lingkungan yang berisiko.

Kata Kunci—Asma, Kualitas Udara, Internet of Things, Machine Learning, Random Forest dan Naive Bayes

Abstract— Asthma is a chronic respiratory disease that can relapse suddenly due to exposure to allergens or poor air quality, and if not properly managed, it may lead to daily activity disruptions and serious complications. To minimize such risks, real-time air quality monitoring is essential, especially for individuals with a history of asthma. This study aims to identify the risk level of asthma relapse at three locations within Universitas Pelita Harapan: the food junction, classroom, and library, by utilizing Internet of Things (IoT) devices and machine learning algorithms. Environmental data were collected in real-time using DHT11 and MQ135 sensors integrated with an ESP8266 microcontroller to measure temperature, humidity, and gas concentration. After calibration and preprocessing, the data were labeled into two categories—at risk and not at risk—based on predefined threshold values. Two machine learning algorithms, Random Forest and Naive Bayes, were applied to build classification models. The results show that the Random Forest model achieved the highest performance with an accuracy of 1.00 and no classification errors, while the Naive Bayes model achieved an accuracy of 0.9476 with minor misclassifications, particularly in the not-at-risk category. Risk distribution visualization indicates that the food junction is the highest-risk location due to elevated gas concentrations from cooking activities, whereas the library has the best air quality. This study demonstrates that the integration of IoT and machine learning can be effectively used to monitor air quality and identify areas that may trigger asthma symptoms, thereby helping individuals with asthma avoid high-risk environments.

Keywords—Asthma, Air Quality, Internet of Things, Machine Learning, Random Forest, Naive Bayes.

I. Latar Belakang

Kasus polusi udara di Indonesia, khususnya pada wilayah Jabodetabek menjadi sorotan serius dalam sebulan terakhir. Tempo.co melaporkan bahwa kualitas udara di Jakarta, Bogor, Depok, Tangerang, dan Bekasi mengalami penurunan drastis dan dikatakan telah melampaui ambang batas aman berdasarkan pemantauan Kementerian Lingkungan Hidup. Sejak 1 Mei hingga 3 Juni 2025, Direktur Perlindungan dan Pengelolaan Mutu Udara menjelaskan bahwa konsentrasi partikel halus PM2.5 di 35 titik kawasan pantau telah berada pada level yang dikategorikan pada status kuning, artinya status tidak sehat karena nilai konsentrasi PM2.5 di atas 100 ppm (*parts per million*), lebih tinggi dari standar, yaitu 55 ppm. Kondisi ini tidak hanya mengancam kesehatan masyarakat secara umum, tetapi juga menjadi pemicu memburuknya penyakit pernapasan seperti asma, khususnya di wilayah dengan kepadatan aktivitas tinggi [1].

Asma merupakan kondisi kronis pada saluran pernapasan yang memengaruhi jutaan individu secara global, ditandai dengan terjadinya penyempitan dan peradangan saluran pernapasan sehingga penderitanya akan kesulitan bernapas. Penderita asma akan mengalami gejala seperti batuk, sesak napas, maupun mengi dan biasanya penderita asma sangat sensitif dengan perubahan kualitas udara hingga ataupun alergen (zat pemicu alergi pada orang yang sensitif) [2]. Keadaan biologis dan lingkungan pada fase awal pertumbuhan individu, seperti berat badan lahir rendah, kelahiran prematur, paparan asap rokok, polusi udara, serta infeksi saluran pernapasan akibat virus, berperan dalam menghambat perkembangan optimal paru-paru dan meningkatkan risiko terjadinya asma. Di samping itu, paparan jangka panjang terhadap alergen dan zat iritan

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

lingkungan, seperti polusi udara dalam dan luar ruangan, tungau, debu rumah, jamur, bahan kimia, asap, dan debu di lingkungan kerja juga diduga merupakan faktor signifikan dalam patogenesis asma. Pada tahun 2019, *World Health Organization* (WHO) mencatat bahwa terdapat 262 juta penderita asma di seluruh dunia dengan sekitar 461.000 kematian terkait asma dan di Indonesia sendiri sekitar 4,5% penduduk atau 12 juta orang telah menderita asma [3].

Berdasarkan penjelasan dari [2] dan paparan kasus yang disebutkan oleh [3], peneliti menyimpulkan bahwa penyakit asma merupakan salah satu penyakit pernapasan yang perlu lebih diperhatikan karena jika penderita asma yang tidak diobati dengan baik dapat mengalami gangguan tidur, kelelahan di siang hari, hingga konsentrasi yang buruk dan dalam jangka panjang dapat menimbulkan kerusakan saluran pernapasan dan paru-paru, gangguan pernapasan kronis, serta peningkatan risiko infeksi paru-paru seperti pneumonia. Alergen dan kualitas udara merupakan pemicu utama asma yang membuat peneliti sadar bahwa pemantauan kualitas udara secara *real-time* sangat dibutuhkan agar individu yang telah memiliki riwayat asma dapat meminimalkan berada di tempat-tempat yang rentan dapat memicu kambuhnya penyakit asma. Oleh karena itu, peneliti ingin melakukan pemetaan area kampus Universitas Pelita Harapan (UPH) dengan mengklasifikasi berdasarkan area dengan kualitas udara yang bisa memperburuk kondisi asma atau aman bagi penderita asma dengan menggunakan *machine learning* (ML).

Machine learning adalah cabang dari *Artificial Intelligence* (AI) yang memungkinkan sistem untuk belajar dari data dan membuat keputusan secara mandiri tanpa arahan eksplisit dari pengembang [4]. Teknologi ini dirancang untuk mengolah data kompleks dan besar dalam berbagai aplikasi, seperti prediksi, klasifikasi, hingga optimasi untuk berbagai bidang. Penelitian yang dilakukan dalam [5] membuktikan bahwa penerapan *machine learning* (ML) dalam bidang medis, khususnya untuk klasifikasi jenis kanker payudara, merupakan sebuah terobosan penting dalam mempercepat proses diagnosis serta pengambilan keputusan klinis. Dengan kemampuannya dalam mengenali pola dari data yang kompleks, algoritma ML seperti *logistic regression*, *decision tree*, *naïve Bayes*, dan *k-nearest neighbor* terbukti mampu mengelompokkan jenis kanker payudara dengan tingkat akurasi yang tinggi, yaitu mencapai 95,00%. Selain digunakan dalam analisis kanker, penerapan ML juga meluas ke berbagai aspek kesehatan lainnya, seperti penelitian yang dilakukan oleh [6] menunjukkan pemanfaatan algoritma *random forest* (RF) untuk mengklasifikasikan penderita penyakit jantung, menegaskan bahwa *machine learning* memiliki potensi besar dalam meningkatkan kualitas diagnosis dan efisiensi layanan kesehatan secara menyeluruh. Penelitian [7] menunjukkan bahwa algoritma RF mampu melakukan klasifikasi dengan memperoleh nilai presisi sebesar 0.823 dan nilai sensitivitas sebesar 0.83, sedangkan penelitian [8] menggunakan algoritma *Naive Bayes* untuk melakukan klasifikasi berita hoax dengan nilai akurasi mencapai 85.28%. Penelitian-penelitian ini menunjukkan bahwa penggunaan *machine learning* merupakan salah satu metode klasifikasi yang efektif di bidang kesehatan, terutama penelitian [7] dan [8] yang membuktikan bahwa, model *machine learning* RF dan *Naive Baye*s dapat digunakan untuk melakukan klasifikasi terhadap tingkat kualitas udara serta mengidentifikasi area yang berpotensi memicu kambuhnya penyakit asma.

Pada penelitian ini, data dikumpulkan secara manual dengan memanfaatkan perangkat *Internet of Things* (IoT). IoT merupakan segala sesuatu yang dapat terhubung ke jaringan internet dan bisa digunakan untuk mengumpulkan data, *monitoring*, hingga melakukan *controlling* [9]. Perangkat IoT yang digunakan dalam penelitian ini, yaitu perangkat mikrokontroler ESP32 pada awal penelitian dan diganti menjadi ESP8266 karena terjadi kesalahan teknis dan mikrokontroler tersebut terintegrasi dengan sensor DHT11 dan sensor MQ135, serta LCD 12ic untuk menampilkan data secara *real-time*. Sensor DHT11 digunakan untuk mengukur parameter suhu dalam *celcius* (°C) dan kelembaban relatif udara yang disajikan dalam persentase (%), sementara sensor MQ135 dengan resistor bawaan 1KΩ digunakan untuk mendeteksi keberadaan gas atau polutan udara dengan membaca nilai analog melalui ADC (*Analog-to-digital converter*). Pengambilan data dilakukan langsung di lingkungan Universitas Pelita Harapan (UPH) pada tiga area berbeda, yaitu area *Food Junction* (FJ), *Johannes Oentoro Library* (JO) dan ruang kelas. Data yang diperoleh dari masing-masing lokasi akan merepresentasikan variasi kualitas udara berdasarkan perbedaan aktivitas dan kondisi lingkungan di setiap area. Selanjutnya, data yang telah dikumpulkan akan diolah dan dianalisis menggunakan algoritma *machine learning*, yaitu *Random Forest* (RF) dan *Naive Bayes* untuk melakukan klasifikasi terhadap tingkat kualitas udara serta mengidentifikasi area yang berpotensi memicu kambuhnya penyakit asma.

II. STATE OF THE ART

Penelitian yang dilakukan oleh [10] telah mengembangkan sistem klasifikasi kualitas air pada budidaya ikan lele menggunakan mikrokontroler ESP32 dan algoritma ML. Sistem ini memanfaatkan sensor suhu, pH, TDS, dan kekeruhan untuk mengukur kualitas air secara *real-time*. Data yang dikumpulkan diproses menggunakan algoritma *K-Nearest Neighbo*r (KNN) dengan bantuan *Principal Component Analysis* (PCA) untuk mereduksi dimensi data agar lebih efisien dijalankan pada ESP8266. Hasil dari penelitian ini adalah model ML yang digunakan mampu mencapai akurasi dalam mengklasifikasi hingga 80%, menghemat memori sekitar 240 byte, dan mempercepat proses komputasi, sehingga efektif untuk implementasi IoT dalam *monitoring* kualitas air.

Lalu peneliti [11] melakukan penelitian lain dengan mengembangkan sistem deteksi perokok aktif secara real-time. Sistem ini menggunakan kamera dan konektivitas IoT untuk mengumpulkan citra kegiatan merokok, lalu menerapkan algoritma ML untuk mendeteksi perilaku tersebut. Tujuannya adalah mendukung konsep kota pintar dengan kemampuan pengawasan otomatis terhadap zona larangan merokok. Metode yang digunakan mencakup pelatihan model deteksi dari kumpulan data citra perokok dan pengintegrasian perangkat keras IoT agar sistem mampu memberi respon cepat terhadap pelanggaran. Hasil penelitian menunjukkan keefektifan sistem dalam mendeteksi perokok aktif secara akurat, menjadikannya solusi potensial untuk implementasi pemantauan publik berbasis kecerdasan buatan dalam mendukung penegakan kebijakan larangan merokok di ruang publik

Selain itu, penelitian [12] yang bertujuan untuk membandingkan kinerja tiga algoritma ML *yaitu K Nearest Neighbor, Naive Bayes*, dan *Decision Tree* dalam mengklasifikasikan kualitas air berdasarkan dataset *Water Potability*. Data yang digunakan telah melalui proses *preprocessing* sebelum dibagi menjadi data pelatihan dan pengujian. Hasil penelitian menunjukkan bahwa algoritma *K Nearest Neighbor* memberikan performa terbaik dengan akurasi mencapai 86,88 persen, mengungguli *Decision Tree* dengan akurasi 80,84 persen dan *Naive Bayes* dengan akurasi 63,60 persen. Dari hasil tersebut, disimpulkan bahwa *K Nearest Neighbor* paling efektif digunakan dalam klasifikasi kualitas air, sementara metode lainnya masih memiliki potensi untuk ditingkatkan melalui pengolahan data atau penambahan jumlah data.

Berdasarkan penelitian [10], [11], dan [12], peneliti dapat menyimpulkan bahwa pemanfaatan IoT dan ML terbukti efektif dalam melakukan pengawasan kondisi lingkungan secara *real-time*. Lalu, perangkat IoT seperti ESP32 yang dilengkapi dengan berbagai sensor juga mampu mengumpulkan data lingkungan secara langsung dan kontinu, seperti suhu, pH, TDS, hingga kekeruhan. Data yang diperoleh dari perangkat IoT akan diolah menggunakan algoritma ML seperti *K-Nearest Neighbor, Naive Bayes*, dan *Decision Tree* yang terbukti mampu melakukan klasifikasi dengan tingkat akurasi yang cukup tinggi. Hal ini menunjukkan bahwa kombinasi teknologi sensor, IoT, dan ML dapat menjadi solusi inovatif untuk pengawasan lingkungan secara cerdas dan responsif.

Oleh karena itu, penelitian ini akan mengembangkan sistem klasifikasi kualitas udara dengan mengintegrasikan perangkat IoT, yaitu ESP8266 yang dipadukan dengan sensor MQ135 dan DHT11 untuk mengidentifikasi kualitas udara dari 3 titik area di lingkungan kampus UPH, serta LCD 12ic untuk menampilkan data secara *real-time*. Data yang diperoleh akan dianalisis menggunakan algoritma *Random Forest* dan *Naive Bayes* untuk membandingkan efektivitas kedua model dalam mengklasifikasi zona berdasarkan tingkat risiko pemicu asma. Meskipun dalam penelitian [12] algoritma *Naive Bayes* menunjukkan akurasi yang lebih rendah dibandingkan model lainnya, namun dalam penelitian ini peneliti ingin membuktikan secara langsung kinerja model tersebut dalam konteks data kualitas udara yang dikumpulkan secara *real-time*. Hasil akhir dari penelitian ini diharapkan dapat memberikan kontribusi nyata dalam mendukung kesehatan, khususnya bagi penderita asma dengan menyediakan informasi mengenai area-area yang berpotensi memicu kambuhnya asma, sehingga individu tersebut dapat lebih waspada dan menghindari area rawan tersebut.

III. METODOLOGI

Penelitian ini dimulai dengan melakukan tinjauan literatur mengenai integrasi perangkat IoT, sensor, serta algoritma ML yang digunakan, yaitu RF dan *Naive Bayes*. RF merupakan salah satu algoritma *ensemble* yang banyak digunakan dalam berbagai aplikasi ML dengan menggabungkan banyak *decision tree* yang dilatih pada *subset* data berbeda untuk meningkatkan akurasi prediksi dan mengurangi risiko *overfitting* [13]. Algoritma ini menggunakan metode pelatihan setiap *decision tree* dengan *subset* acak dari *training* data dan hasil akhirnya ditentukan melalui voting (untuk klasifikasi) atau rata-rata (untuk regresi). RF terkenal karena fleksibilitasnya dalam menangani data set yang besar dan kompleks, termasuk data dengan fitur yang saling berinteraksi. Sementara itu, *Naive Bayes* adalah suatu algoritma klasifikasi yang berdasar pada teorema *Bayes*, yaitu memprediksi peluang di masa depan berdasarkan pengalaman di masa sebelumnya [14]. Algoritma *Naive Bayes* didasarkan pada asumsi yang kuat bahwa setiap atribut atau kondisi dalam data bersifat saling independen satu sama lain, terlepas dari keberadaan atribut lainnya. Algoritma ini menghitung probabilitas bersyarat dengan mengasumsikan bahwa setiap kelas keputusan tersebut adalah benar, estimasi probabilitas dilakukan berdasarkan frekuensi kemunculan atribut dalam tabel keputusan utama (*master table*) sebagai dasar perhitungan. Berdasarkan [13] dan [14], peneliti menemukan perbedaan antara kedua algoritma tersebut, sehingga peneliti ingin menggunakan algoritma RF dan *Naive Bayes* untuk mengidentifikasi serta membandingkan performa kedua algoritma dalam mengklasifikasi 3 titik di area UPH yang dapat memicu kambuhnya asma dengan menggunakan kualitas udara sebagai parameternya.

Setelah melakukan tinjauan literatur, peneliti mulai membuat rangkaian perangkat IoT yang digunakan untuk pengumpulan data secara manual. Rangkaian perangkat IoT tersebut terdiri dari ESP8266, sensor DHT11 dan MQ135, serta LCD 12ic yang dirangkai seperti Gambar 1.

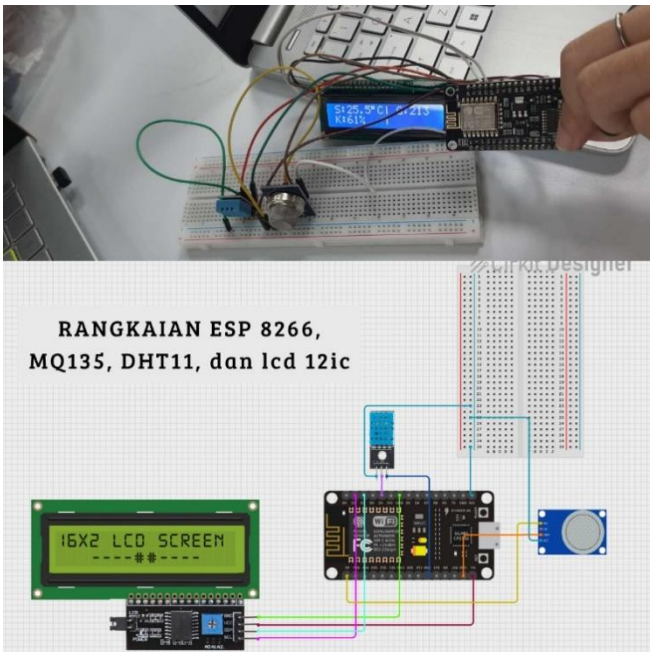

Gambar 1. Rangkaian ESP8266, MQ135, DHT11, dan LCD12ic

Rangkaian tersebut akan diprogram menggunakan Arduino IDE agar sensor dapat terhubung ke jaringan Wi-Fi dan memperoleh data hasil pengukuran suhu, kelembapan, dan gas secara akurat. Sistem pengambilan data ini diawali dengan menghubungkan perangkat ESP8266 ke jaringan Wi-Fi menggunakan SSID (*Service Set Identifier*) dan *password* yang telah dikonfigurasi, koneksi inilah yang memungkinkan ESP8266 untuk mengakses broker MQTT berbasis *cloud*. Setelah terhubung, ESP8266 akan membaca kondisi lingkungan melalui dua sensor utama, yaitu DHT11 untuk suhu dan kelembapan, serta MQ135 untuk mendeteksi kualitas udara berdasarkan keberadaan gas berbahaya.

Sensor-sensor ini dipasang langsung pada mikrokontroler dan melakukan pembacaan data secara berkala.

Data hasil pengukuran kemudian dikirimkan melalui protokol MQTT ke *HiveMQ Cloud*, yaitu broker MQTT berbasis *cloud* yang mendukung komunikasi terenkripsi (SSL/TLS) melalui port 8883. Dalam skema ini, ESP8266 bertindak sebagai *publisher* yang mengirimkan data dalam format JSON ke topik *esp/data* setiap 15 detik, mencakup nilai suhu, kelembapan, dan konsentrasi gas. Protokol *mqtts* digunakan untuk menjamin keamanan transmisi, dilengkapi autentikasi berbasis *username* dan *password*.

Selanjutnya, data yang dipublikasikan oleh ESP8266 diterima oleh server Node.js yang berperan sebagai *subscriber* MQTT dan server ini terhubung ke topik yang sama dengan kredensial yang telah ditentukan dan secara otomatis memproses setiap pesan baru yang diterima. Data dalam format JSON kemudian diurai dan disimpan ke dalam *database cloud Supabase* yang berbasis *PostgreSQL*, menggunakan Prisma ORM. Untuk menjaga efisiensi koneksi dan keamanan, server menggunakan *connection pooling* melalui *PgBouncer* pada *port* 6543 dengan kredensial *database* yang disimpan aman dalam *file .env*. Selain disimpan ke dalam *database*, data sensor juga ditampilkan secara *real-time* pada layar LCD12ic dan tampilan ini akan diperbarui setiap 15 detik untuk memberikan informasi suhu, kelembapan, dan gas kepada pengguna secara langsung.

Pengambilan data tersebut diambil di 3 titik area UPH yang berbeda, yaitu FJ (Gambar 2), JO (Gambar 3), dan ruang kelas (Gambar 4) hingga data memenuhi standar minimal yaitu 1.700 data untuk setiap tempatnya dengan total keseluruhan data mencapai minimal 5.000 data seperti cuplikan hasil pengumpulan data yang bisa dilihat pada Gambar 5.

Gambar 2. Pengambilan Data di FJ

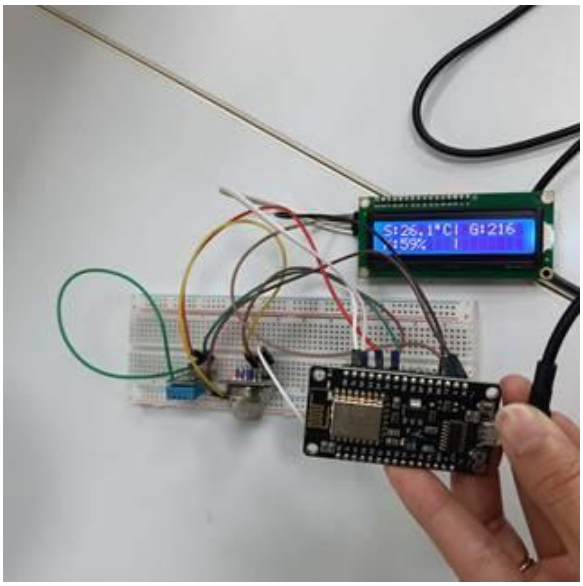

Gambar 3. Pengambilan Data di JO

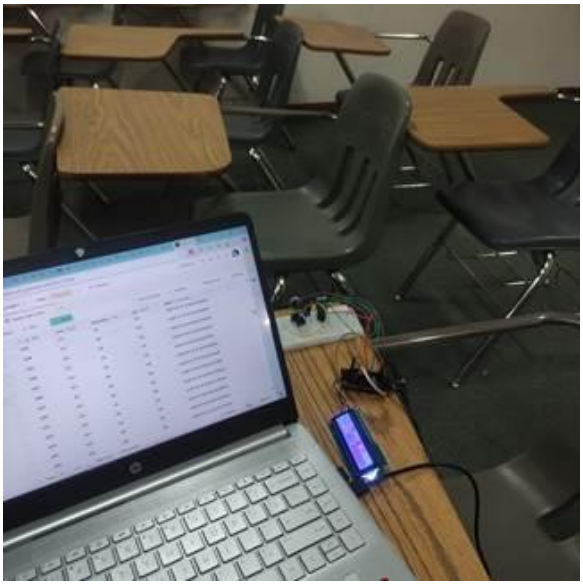

Gambar 4. Pengambilan Data di Ruang Kelas

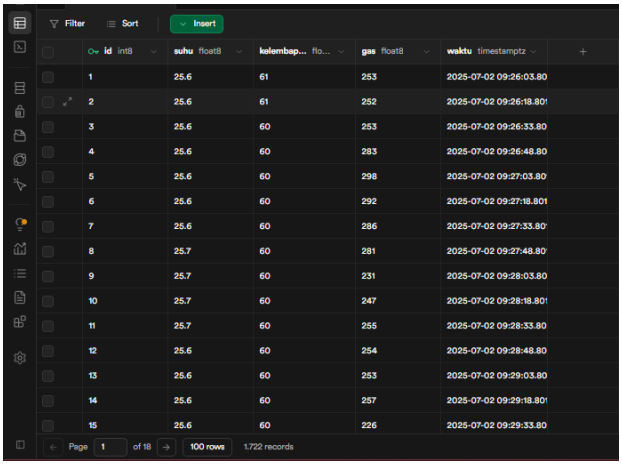

id int8	suhu float8	kelembap... flo...	gas float8	waktu timestamptz
1	25.6	61	253	2025-07-02 09:26:03.80
2	25.6	61	252	2025-07-02 09:26:18.801
3	25.6	60	253	2025-07-02 09:26:33.80
4	25.6	60	283	2025-07-02 09:26:48.80
5	25.6	60	298	2025-07-02 09:27:03.80
6	25.6	60	292	2025-07-02 09:27:18.801
7	25.6	60	286	2025-07-02 09:27:33.80
8	25.7	60	281	2025-07-02 09:27:48.80
9	25.7	60	231	2025-07-02 09:28:03.80
10	25.7	60	247	2025-07-02 09:28:18.801
11	25.7	60	255	2025-07-02 09:28:33.80
12	25.6	60	254	2025-07-02 09:28:48.80
13	25.6	60	253	2025-07-02 09:29:03.80
14	25.6	60	257	2025-07-02 09:29:18.801
15	25.6	60	226	2025-07-02 09:29:33.80

Gambar 5. Cuplikan Hasil Pengambilan Data

Selanjutnya, setelah menyelesaikan tinjauan literatur dan pengumpulan data, data akan melalui tahapan *preprocessing*, yang salah satu langkah pentingnya adalah kalibrasi terhadap data gas. Kalibrasi ini menjadi krusial karena terdapat

perbedaan jenis mikrokontroler yang digunakan dalam proses pengambilan data, yaitu ESP32 dan ESP8266. Perbedaan perangkat ini dapat menyebabkan ketidaksesuaian dalam nilai pembacaan sensor, terutama pada parameter gas yang menjadi salah satu komponen penting dalam analisis. Dalam hal ini, peneliti menetapkan ESP8266 sebagai acuan standar karena perangkat tersebut lebih banyak digunakan pada titik pengukuran. Oleh karena itu, seluruh data gas yang berasal dari ESP32 perlu disesuaikan atau dikalibrasi agar konsisten dengan standar pembacaan dari ESP8266. Proses kalibrasi ini dilakukan untuk memastikan bahwa seluruh data yang digunakan dalam pelatihan model memiliki kesetaraan dalam skala pengukuran, sehingga tidak menimbulkan bias atau kesalahan dalam proses pemodelan.

Setelah proses kalibrasi selesai, peneliti melanjutkan dengan menggabungkan data dari tiga titik lokasi yang berbeda. Penggabungan data dari berbagai lokasi ini bertujuan untuk memperkaya variasi data dan memperluas cakupan karakteristik lingkungan yang akan dianalisis. Langkah selanjutnya dalam tahap *preprocessing* data adalah melakukan pemeriksaan secara menyeluruh terhadap seluruh data yang telah digabungkan. Pemeriksaan ini mencakup beberapa aspek penting untuk memastikan kualitas dan kesiapan data sebelum dimasukkan ke dalam model, antara lain pengecekan konsistensi format data, identifikasi terhadap nilai-nilai yang hilang (*missing values*), serta deteksi dan penghapusan data yang bersifat duplikat atau redundan.

Setelah tahap *preprocessing selesai*, peneliti melanjutkan dengan melakukan proses pelabelan terhadap setiap baris data untuk menentukan kualitasnya. Dalam pendekatan ini, pelabelan dilakukan berdasarkan kualitas masing-masing parameter sensor, yaitu suhu, kelembapan, dan gas. Setiap parameter dikategorikan sebagai tidak beresiko (1) atau beresiko (0) sesuai dengan ambang rentang ideal: suhu antara 14,8°C [15] hingga 30°C [16], kelembapan antara 40% hingga 60% [17] , dan gas di bawah 314 (berdasarkan nilai ADC mentah). Nilai ambang 314 untuk sensor gas MQ135 ditentukan berdasarkan pengamatan langsung yang dilakukan peneliti. Saat sensor MQ135 diberikan paparan asap secara langsung, nilai modus yang paling sering muncul adalah 397. Sementara itu, ketika sensor diletakkan di area dengan udara bersih, nilai modus yang tercatat adalah 231. Berdasarkan dua kondisi ekstrem tersebut, peneliti menetapkan ambang batas gas pada nilai 314, yang merupakan titik tengah antara dua pengamatan tersebut, sebagai batas toleransi kualitas udara. Data kemudian dilabeli sebagai "tidak berisiko" jika ketiga parameter berada dalam rentang ideal, dan "berisiko" apabila salah satu atau lebih berada di luar batas tersebut. Proses pelabelan ini bersifat biner dan berperan sebagai target variabel dalam pelatihan model *machine learning*. Dengan pendekatan ini, model diharapkan mampu mengenali kombinasi kondisi lingkungan yang berpotensi menimbulkan risiko kambuhnya asma, serta membuat prediksi terhadap data baru secara lebih akurat dan andal. Kemudian, data akan dibagi menjadi 80% data latih dan 20% data uji, hingga menerapkan model RF serta *Naive Bayes* untuk mengklasifikasi berdasarkan target yang dipilih. Pada tahap akhir, peneliti akan membuat visualisasi berupa *confusion matrix* hasil kerja model dan mengetahui rata-rata fitur yang bisa menyebabkan kambuhnya asma.

IV. HASIL

Berdasarkan tahapan-tahapan yang telah dilakukan, pada tahap *preprocessing* menunjukkan bahwa data dari ketiga lokasi yang berbeda berhasil digabungkan dengan baik dan tidak ditemukan adanya nilai yang hilang (*missing values*) pada keseluruhan *dataset*. Hal ini mengindikasikan bahwa data telah dikumpulkan secara lengkap dan konsisten. Selain itu, hasil pemeriksaan juga menunjukkan bahwa tidak terdapat data yang bersifat duplikat, sehingga seluruh data dapat langsung digunakan dalam proses pelatihan model tanpa perlu dilakukan penghapusan.

Selanjutnya, pada proses *labeling* yang bertujuan untuk memberikan kategori tingkat risiko asma pada setiap baris data, penentuan label dilakukan berdasarkan nilai dari parameter lingkungan yang direkam, seperti konsentrasi gas, suhu, dan kelembapan. Kategori risiko asma dibagi menjadi dua kelas, yaitu berisiko dan tidak berisiko. Penetapan label ini dilakukan dengan menggunakan ambang batas tertentu yang telah ditetapkan berdasarkan hasil analisis awal terhadap distribusi data serta referensi medis atau lingkungan yang relevan.

Hasil dari proses *labeling* kemudian divisualisasikan dalam bentuk diagram batang untuk menunjukkan distribusi jumlah data pada masing-masing kategori risiko. Gambar 6 menampilkan visualisasi distribusi risiko asma yang menjelaskan bahwa jumlah data terbanyak berada pada kategori beresiko, yaitu lebih dari 4.000 data. Selanjutnya, kategori tidak beresiko memiliki jumlah yang jauh lebih sedikit, yaitu kurang dari 1.000 data. Ketimpangan distribusi ini memberikan gambaran bahwa sebagian besar data yang dikumpulkan berasal dari lingkungan atau kondisi yang berpotensi tinggi dalam memicu kambuhnya asma.

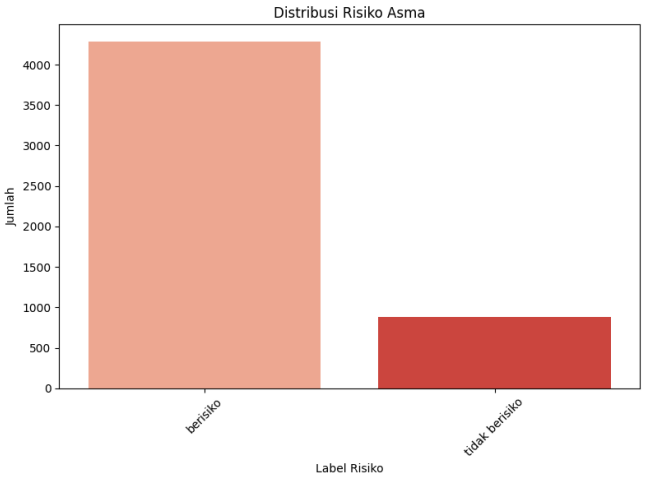

Gambar 6. Diagram Distribusi Risiko Asma

Data yang telah melewati *preprocessing*, selanjutnya data akan digunakan dalam pembuatan model RF. Data set akan dibagi menjadi 80% data latih dan 20% data uji karena peneliti menganggap bahwa ini merupakan pembagian yang ideal supaya tidak terjadi *overfitting*. Selanjutnya, model RF

akan dibuat dan akan dilatih dan diuji menggunakan data yang telah dibagi pada tahap sebelumnya. Berdasarkan model RF yang telah dibuat, berikut merupakan hasil model.

```
 Random Forest
Akurasi = 1.0

Classification Report:
                precision    recall  f1-score   support

      berisiko       1.00      1.00      1.00       856
tidak berisiko       1.00      1.00      1.00       176

      accuracy                           1.00      1032
     macro avg       1.00      1.00      1.00      1032
  weighted avg       1.00      1.00      1.00      1032
```

Gambar 7. Hasil Model *Random Forest*

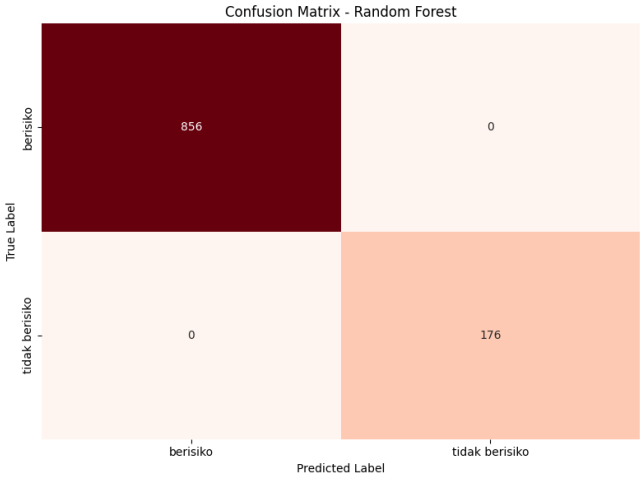

Gambar 8. *Confusion Matrix Random Forest*

Berdasarkan Gambar 7 dan Gambar 8, model *Random Forest* menghasilkan akurasi sebesar 1.00 yang berarti model berhasil memprediksi dengan benar seluruh sampel pada data uji yang berjumlah 1.042. Pada kategori berisiko, model memiliki nilai *precision* sebesar 1.00 yang menunjukkan bahwa 100% dari prediksi yang diklasifikasikan sebagai berisiko memang benar. Nilai *recall* untuk kategori ini juga sebesar 1.00, menandakan bahwa seluruh data berisiko yang sebenarnya berhasil dikenali oleh model, serta nilai *f1-score* pun mencapai 1.00, mencerminkan keseimbangan sempurna antara *precision* dan *recall*.

Pada kategori tidak berisiko, model menunjukkan *precision* sebesar 1.00, *recall* sebesar 1.00, dan f1-score sebesar 1.00. Hal ini menunjukkan bahwa model tidak melakukan kesalahan dalam klasifikasi, baik dalam mengenali data yang sebenarnya maupun dalam menghindari klasifikasi yang salah. Secara rata-rata, *macro averag*e untuk *precision, recall*, dan *f1-score* masing-masing adalah 1.00, dan *weighted average* juga menunjukkan nilai 1.00 untuk ketiga metrik tersebut. Ini mengindikasikan bahwa model bekerja secara optimal pada semua kelas tanpa adanya ketimpangan.

Dalam upaya mengevaluasi model, peneliti ingin memvisualisasikan Gambar 7 ke dalam *confusion matrix* yang bisa dilihat pada Gambar 8. Berdasarkan Gambar 8, Sebanyak 856 data dengan label asli berisiko diklasifikasikan dengan benar sebagai berisiko dan 176 data dengan label tidak berisiko juga diprediksi dengan benar sebagai tidak berisiko. Tidak terdapat kesalahan klasifikasi, sehingga nilai *false positive* adalah 0 dan nilai *false negative*, yaitu 0. Dengan total 1.042 prediksi benar dari 1.042 data, model ini memberikan hasil klasifikasi yang sangat akurat dan sempurna. Hasil ini menunjukkan bahwa model RF memiliki kinerja yang sangat kuat dan efektif dalam membedakan antara kategori berisiko dan tidak berisiko berdasarkan data lingkungan.

Peneliti ingin mencoba menerapkan *dataset* ke dalam model yang berbeda dengan harapan, oleh karena itu peneliti membuat model *Naive Bayes* untuk melakukan klasifikasi berbasis probabilitas. Model yang telah dibuat akan dilatih dan diuji, sehingga mendapatkan hasil berikut.

```
 Naive Bayes
Akurasi = 0.9476744186046512

Classification Report:
                precision    recall  f1-score   support

      berisiko       0.99      0.95      0.97       856
tidak berisiko       0.80      0.93      0.86       176

      accuracy                           0.95      1032
     macro avg       0.89      0.94      0.91      1032
  weighted avg       0.95      0.95      0.95      1032
```

Gambar 9. Hasil Model *Naive Bayes*

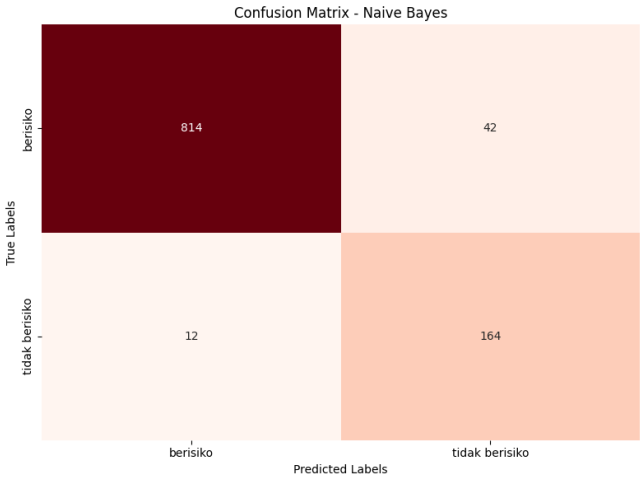

Gambar 10. *Confusion Matrix Naive Bayes*

Berdasarkan hasil pengujian model *Naive Bayes* pada dua kelas, yaitu berisiko dan tidak berisiko, diperoleh akurasi sebesar 0.9476. Artinya, model berhasil memprediksi dengan benar sekitar 94.76% dari total 1.032 data uji. Pada kategori berisiko, model menunjukkan performa tinggi dengan *precision* sebesar 0.99, yang berarti 99% dari seluruh prediksi untuk kelas ini benar. *Recall* sebesar 0.95 menunjukkan bahwa model berhasil mengenali 95% dari seluruh data aktual yang termasuk dalam kategori berisiko. Nilai f1-score sebesar 0.97 mencerminkan keseimbangan yang sangat baik antara presisi dan recall pada kelas ini.

Sementara itu, pada kategori tidak berisiko, model mencatat *precision* sebesar 0.80, yang berarti 80% dari prediksi untuk kelas ini benar. *Recall* sebesar 0.93 menunjukkan bahwa model mampu mengenali 93% dari semua data aktual yang termasuk dalam kategori ini. Dengan f1-score sebesar 0.86, performa model pada kelas tidak berisiko tergolong baik, meskipun lebih rendah dibandingkan kelas berisiko. Nilai *macro average* untuk *precision, recall*,

dan *f1-score* masing-masing sebesar 0.89, 0.94, dan 0.91 menunjukkan rata-rata performa model tanpa mempertimbangkan jumlah sampel per kelas. Sedangkan *weighted average* ketiganya sama-sama sebesar 0.95, menunjukkan bahwa secara keseluruhan model mampu memberikan performa tinggi dan seimbang berdasarkan proporsi data.

Visualisasi hasil klasifikasi dalam bentuk *confusion matrix* mendukung laporan evaluasi tersebut. Dari 176 data tidak berisiko, 164 data diklasifikasikan dengan benar, dan 12 data diklasifikasikan salah sebagai berisiko. Sedangkan dari 814 data berisiko, 814 data berhasil diprediksi dengan benar, dan 42 data diklasifikasikan salah sebagai tidak berisiko. Meskipun masih terdapat sejumlah kesalahan prediksi, terutama pada kategori berisiko, performa keseluruhan model tetap sangat baik. Model *Naive Bayes* ini menunjukkan kemampuan yang kuat dalam mengenali kondisi yang berisiko, yang menjadi prioritas utama dalam konteks sistem deteksi dini risiko asma.

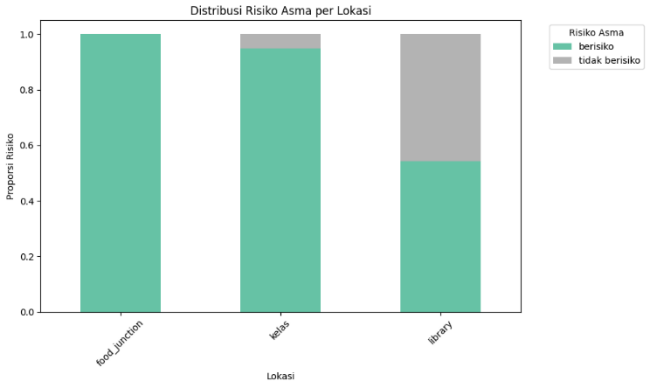

Gambar 11. Diagram Distribusi Risiko Asma di Tiap Lokasi

Peneliti juga membuat visualisasi distribusi risiko asma di tiap lokasi agar peneliti dapat mengetahui area mana yang memiliki berisiko menyebabkan kambuhnya asma. Berdasarkan Gambar 11, pada lokasi *food junction*, seluruh data tergolong dalam kategori berisiko, yang mengindikasikan bahwa lingkungan di area tersebut memiliki kualitas udara yang sangat buruk. Salah satu penyebab utama kemungkinan berasal dari banyaknya asap hasil proses memasak yang terakumulasi di area tersebut, sehingga meningkatkan konsentrasi partikel dan gas berbahaya di udara yang dapat memicu kambuhnya asma. Di lokasi kelas, mayoritas data juga tergolong berisiko, meskipun terdapat sedikit proporsi data yang termasuk kategori aman, menandakan bahwa kondisi lingkungan di kelas masih kurang ideal. Sementara itu, lokasi *library* menunjukkan proporsi yang lebih seimbang antara data aman dan berisiko, dengan sekitar setengah dari data tergolong aman yang mengindikasikan bahwa area ini memiliki kualitas lingkungan yang lebih baik dibanding dua lokasi lainnya. Visualisasi ini memberikan gambaran penting bahwa tingkat risiko asma sangat bervariasi tergantung pada lokasi, sehingga dapat menjadi dasar dalam menetapkan prioritas perbaikan kualitas lingkungan.

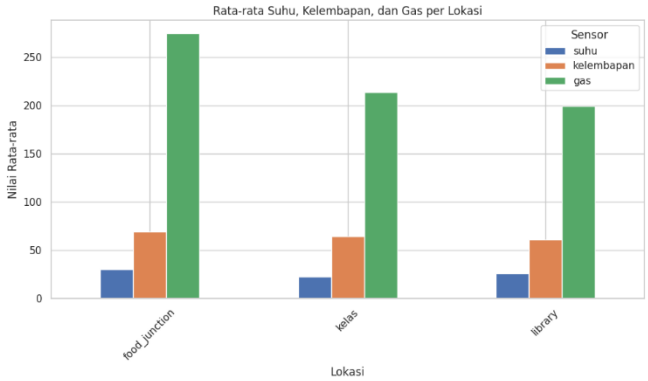

Gambar 12. Diagram Rata-Rata Suhu, Kelembaban, dan Gas per Lokasi

Gambar 12 memperlihatkan rata-rata nilai suhu, kelembapan, dan konsentrasi gas pada tiga lokasi berbeda, yaitu *food junction*, kelas, dan *library*. Dari grafik tersebut, terlihat bahwa lokasi *food junction* memiliki nilai gas tertinggi, yaitu di atas 270 serta kelembapan tertinggi dibandingkan dua lokasi lainnya, yaitu sekitar 70. Suhu di *food junction* juga lebih tinggi dibanding kelas dan perpustakaan. Hal ini mengindikasikan bahwa lingkungan di *food junction* memiliki kualitas udara yang lebih buruk, kemungkinan besar akibat aktivitas memasak yang menghasilkan asap dan emisi gas, sehingga meningkatkan paparan terhadap zat berbahaya. Di lokasi kelas, nilai rata-rata gas lebih rendah dibanding *food junction*, yaitu sekitar 210, dengan kelembapan dan suhu yang juga sedikit lebih rendah, menunjukkan kondisi udara yang relatif lebih stabil namun masih perlu perhatian. Sementara itu, di *library*, konsentrasi gas tercatat paling rendah di antara ketiga lokasi, yaitu mendekati 200 dengan suhu dan kelembapan yang sedikit lebih rendah dari dua lokasi lainnya. Hal ini menunjukkan bahwa perpustakaan memiliki kualitas udara terbaik dan paling aman bagi pernapasan, serta lebih mendukung kesehatan bagi penderita asma. Grafik ini secara keseluruhan mendukung analisis sebelumnya bahwa kualitas udara yang buruk, khususnya tingginya konsentrasi gas, menjadi faktor utama dalam peningkatan risiko asma di suatu lokasi.

V. KESIMPULAN

Berdasarkan hasil penelitian yang dilakukan, dapat disimpulkan bahwa integrasi perangkat IoT dengan algoritma *machine learning* memiliki potensi besar dalam mendukung sistem pemantauan kualitas udara yang sensitif terhadap risiko kambuhnya penyakit asma. Penelitian ini berhasil mengembangkan sistem yang mengukur parameter lingkungan seperti suhu, kelembapan, dan konsentrasi gas pada tiga titik lokasi di lingkungan Universitas Pelita Harapan, yaitu *food junction*, ruang kelas, dan perpustakaan dengan menggunakan sensor DHT11 dan MQ135 yang terhubung ke mikrokontroler ESP8266. Setelah melalui proses kalibrasi dan *preprocessing*, data diklasifikasikan ke dalam dua kategori, yaitu berisiko dan tidak berisiko terhadap asma. Penelitian ini juga menggunakan dua algoritma ML, yaitu *Random Forest* dan *Naive Bayes* yang digunakan untuk membandingkan performa dalam klasifikasi data tersebut.

Hasil menunjukkan bahwa model RF memberikan kinerja yang sangat baik dengan akurasi sebesar 1.00, *precision, recall*, dan *f1-score* yang semuanya sempurna pada

kedua kelas, serta tidak terdapat kesalahan klasifikasi sama sekali. Sementara itu, model *Naive Bayes* juga menunjukkan performa yang cukup tinggi dengan akurasi sebesar 0.9476, tetapi masih menghasilkan beberapa kesalahan klasifikasi, terutama pada kategori tidak berisiko. Dari visualisasi *confusion matrix*, model *Naive Bayes* salah mengklasifikasikan 42 data berisiko sebagai tidak berisiko dan 12 data tidak berisiko sebagai berisiko yang menunjukkan bahwa meskipun secara umum efektif, model ini kurang tepat dalam mendeteksi kelas minoritas.

Hasil menunjukkan bahwa model RF memberikan kinerja yang sangat baik dengan akurasi sebesar 1.00, *precision, recall*, dan *f1-score* yang semuanya sempurna pada kedua kelas, serta tidak terdapat kesalahan klasifikasi sama sekali. Sementara itu, model *Naive Bayes* juga menunjukkan performa yang cukup tinggi dengan akurasi sebesar 0.9476, tetapi masih menghasilkan beberapa kesalahan klasifikasi, terutama pada kategori tidak berisiko. Berdasarkan *confusion matrix*, model *Naive Bayes* salah mengklasifikasikan 42 data berisiko sebagai tidak berisiko dan 12 data tidak berisiko sebagai berisiko, yang menunjukkan bahwa meskipun secara umum efektif, model ini masih memiliki kelemahan dalam menangani ketidakseimbangan data. Oleh karena itu, dapat disimpulkan bahwa RF merupakan model yang lebih baik dalam penelitian ini, karena memberikan hasil prediksi yang sempurna, stabil, dan sangat akurat dalam membedakan tingkat risiko asma berdasarkan parameter lingkungan.

Selain membandingkan performa model, penelitian ini juga mengidentifikasi lokasi yang paling berisiko terhadap kambuhnya asma. Berdasarkan visualisasi distribusi risiko dan grafik rata-rata parameter lingkungan, ditemukan bahwa *food junction* merupakan lokasi dengan tingkat risiko tertinggi. Hal ini didukung oleh data yang menunjukkan bahwa seluruh sampel dari *food junction* masuk dalam kategori berisiko. Visualisasi juga memperlihatkan bahwa lokasi ini memiliki konsentrasi gas tertinggi, serta suhu dan kelembapan yang relatif lebih tinggi dibanding dua lokasi lainnya. Faktor-faktor ini kemungkinan besar disebabkan oleh asap dari aktivitas memasak di area tersebut yang menyebabkan akumulasi gas berbahaya di udara dan menurunkan kualitas udara secara signifikan. Sebaliknya, lokasi perpustakaan menunjukkan kualitas udara terbaik, dengan distribusi data yang lebih seimbang antara berisiko dan tidak berisiko, serta rata-rata nilai gas dan kelembapan yang lebih rendah. Dengan demikian, hasil visualisasi ini mendukung kesimpulan bahwa tingkat risiko asma sangat dipengaruhi oleh kondisi lingkungan di masing-masing lokasi, dan informasi ini penting untuk pengambilan keputusan dalam upaya menciptakan ruang yang lebih aman bagi penderita asma.

Dengan adanya penelitian ini, diharapkan bahwa masyarakat dan generasi muda semakin menyadari pentingnya menjaga kualitas udara di lingkungan sekitar sebagai bagian dari gaya hidup sehat, khususnya bagi individu yang rentan terhadap penyakit pernapasan seperti asma. Penerapan sistem *monitoring* berbasis IoT dan *machine learning* ini tidak hanya bermanfaat dalam konteks akademik, tetapi juga memiliki potensi untuk diimplementasikan di ruang-ruang publik, sekolah, atau fasilitas kesehatan untuk memberikan peringatan dini terhadap potensi risiko. Peneliti juga berharap agar tenaga medis dan instansi terkait dapat memanfaatkan sistem ini sebagai alat bantu dalam memberikan edukasi dan rekomendasi kesehatan lingkungan kepada pasien. Dengan adanya tindakan preventif dan kesadaran kolektif terhadap pentingnya kualitas udara, diharapkan angka kambuhnya asma dapat ditekan dan masyarakat dapat hidup dengan kualitas kesehatan pernapasan yang lebih baik.

Langkah selanjutnya yang dapat dilakukan untuk menyempurnakan sistem ini adalah melakukan penambahan jenis sensor yang lebih sensitif atau spesifik terhadap polutan udara lain yang berkontribusi pada risiko asma, seperti PM2.5 atau karbon monoksida. Selain itu, pengumpulan data dalam jangka waktu yang lebih panjang serta perluasan cakupan lokasi pemantauan akan meningkatkan keandalan model prediksi. Implementasi sistem ini secara *real-time* dan terintegrasi dengan notifikasi peringatan dini juga dapat sangat membantu pengguna dalam menghindari paparan lingkungan berisiko tinggi. Dengan langkah-langkah ini, sistem tidak hanya menjadi alat *monitoring* pasif, tetapi juga menjadi solusi aktif untuk pencegahan risiko asma.

DAFTAR PUSTAKA

[1] M. P. Mahadewi and E. Can, "Polusi udara: Poin-Poin surat edaran menteri Lingkungan Hidup," Tempo, https://www.tempo.co/lingkungan/polusi-udara-poin-poin-surat-edaran-menteri-lingkungan-hidup-1653051 (accessed Jul. 15, 2025).

[2] S. H. Pratiwi, "Tinjauan Literatur Sistematis: Sistem Pemantauan Kualitas udara bagi penderita asma," Repository Nusa Putra University, https://repository.nusaputra.ac.id/id/eprint/1387/ (accessed Jul. 15, 2025).

[3] World Health Organization , "Asthma," World Health Organization, https://www.who.int/news-room/fact-sheets/detail/asthma (accessed Jul. 15, 2025).

[4] M. R. S. Alfarizi, M. Z. Al-farish, M. Taufiqurrahman, G. Ardiansah, and M. Elgar, "Penggunaan Python Sebagai Bahasa Pemrograman untuk machine learning Dan Deep Learning," Karimah Tauhid, https://ojs.unida.ac.id/karimahtauhid/article/view/7518 (accessed Jul. 15, 2025).

[5] N. R. Muntiari and K. H. Hanif, "Klasifikasi Penyakit Kanker Payudara Menggunakan perbandingan algoritma machine learning," Jurnal Ilmu Komputer dan Teknologi, https://ejournal.uhb.ac.id/index.php/IKOMTI/article/view/766 (accessed Jul. 15, 2025).

[6] B. Hirwono, A. Hermawan, and D. Avianto, "Lembaga Kita Open Journal Systems," Lembaga KITA Open Journal Systems, https://journal.lembagakita.org/ (accessed Jul. 15, 2025).

[7] M. M. Mutoffar, M. Naseer, and A. Fadillah, "Klasifikasi Kualitas Air Sumur Menggunakan algoritma random forest," Naratif, https://naratif.utb-univ.ac.id/index.php/naratif/article/view/160 (accessed Jul. 15, 2025).

[8] H. Mustofa and A. A. Mahfudh, "Klasifikasi Berita hoax Dengan Menggunakan metode naive Bayes," Walisongo Journal of Information Technology, https://journal.walisongo.ac.id/index.php/jit/article/view/3915 (accessed Jul. 15, 2025).

[9] A. Junaidi, "Internet of things, Sejarah, Teknologi Dan Penerapannya : Review," Jurnal Ilmiah Teknologi Infomasi Terapan, https://journal.widyatama.ac.id/index.php/jitter/article/view/66 (accessed Jul. 15, 2025).

[10] F. Aulady, D. Syauqy, and R. R. M. Putri, "Jurnal Pengembangan teknologi informasi Dan Ilmu komputer," istem Klasifikasi Kualitas Air dalam Akuakultur Budidaya Ikan Lele dengan Algoritma PCA dan KNN, https://j-ptiik.ub.ac.id/index.php/j-ptiik (accessed Jul. 15, 2025).

[11] A. Abdillah, B. K. Nayu, S. Setianingsih, G. B. Hidayat, and T. R. Ahmad, "DESMOCAM (detection smoking camera): Integration of IOT and machine learning for active smoker detection to support Smart Cities in Indonesia," Jurnal Teknik Informatika (Jutif),

https://jutif.if.unsoed.ac.id/index.php/jurnal/article/view/2181 (accessed Jul. 15, 2025).

[12] A. Tangkelayuk, "Jatisi (Jurnal Teknik Informatika Dan Sistem Informasi)," The Klasifikasi Kualitas Air Menggunakan Metode KNN, Naïve Bayes, dan Decision Tree, https://jurnal.mdp.ac.id/index.php/jatisi/article/view/2048 (accessed Jul. 15, 2025).

[13] S. Lee, C. Lee, K. G. Mun, and D. Kim, "Decision tree algorithm considering distances between classes | IEEE Journals & Magazine | IEEE Xplore," Decision Tree Algorithm Considering Distances Between Classes, https://ieeexplore.ieee.org/document/9810212/ (accessed Jul. 15, 2025).

[14] M. S. Mustafa, M. R. Ramadhan, and A. P. Thenata, "Implementasi data mining untuk Evaluasi Kinerja Akademik Mahasiswa menggunakan algoritma naive Bayes classifier," Creative Information Technology Journal, https://citec.amikom.ac.id/main/index.php/citec/article/view/106 (accessed Jul. 15, 2025).

[15] Y. Zhang, J. Yang, S. Chen, M. Zhang, and J. Zhang, "Effects of Meteorological Factors on Asthma Hospital Visits in Haikou City, China," *Atmosphere (Basel)*, vol. 15, no. 3, Mar. 2024, doi: 10.3390/atmos15030328 (accessed Jul. 16, 2025).

[16] H. C.-y. Lam, A. M. Li, E. Y.-y. Chan, and W. B. Goggins, "The short-term association between asthma hospitalisations, ambient temperature, other meteorological factors and air pollutants in Hong Kong: a time-series study," Thorax, vol. 71, no. 12, pp. 1097–1109, 2016, doi: 10.1136/thoraxjnl-2015-208054. (accessed Jul. 16, 2025).

[17] N. D. B. Ehelepola, K. Ariyaratne, and A. Jayaratne, "The association between local meteorological changes and exacerbation of acute wheezing in Kandy, Sri Lanka," Glob Health Action, vol. 11, no. 1, Jan. 2018, doi: 10.1080/16549716.2018.1482998 (accessed Jul. 16, 2025).

LINK GOOGLE COLAB

https://colab.research.google.com/drive/1nn4IWjsgsKUSKj4guXUkHoxM0Qmq3AD2?usp=sharing